

SMARCLE 2021 winter study Team 3

# 참 거짓 판단 장치 〈 로지스틱 회귀 〉

Logistic Regression

17 김찬영, 17 최태규, 18 장윤정, 20 김준수

# Contents

18 장운정

로지스틱 회귀에 관한 이론

17 최태규

로지스틱 회귀 실습코드 설명

17 김찬영

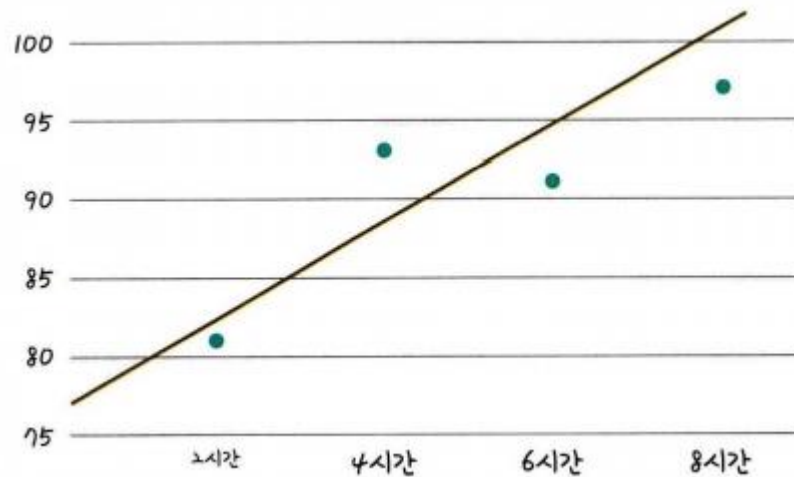
실습코드 개조 및 토론 & 로지스틱 회귀에서 퍼셉트론으로

# 01 이론

## 01


## 로지스틱 회귀

## 선형 회귀 (Linear Regression)



연속형 input → 연속형 output

## 로지스틱 회귀 (Logistic Regression)



연속형 input → 이산형 output

# 01

## 로지스틱 회귀

### 로지스틱 회귀의 사용

- 범주형 적 의사결정을 필요로 하는 모델 ex) 제품이 불량인지 정상인지, 고객이 이탈고객인지 잔류고객인지  
페이스북 피드를 보여줄지 숨길지, 메일이 스팸인지 햄인지 등

1. 이진변수 ex) 성공/실패, 사망/생존 -> binary classification
2. 멀티변수 -> Multi-Class Classification

How?

로지스틱 회귀  
원리 이용

참거짓  
판단장치  
모델 생성

새로운 질문이  
들어오면?

모델의 범주 중  
하나로 예측

## 01

## 로지스틱 회귀



1 (Cat)



0 (Non Cat)



0 (Non Cat)

$$y = \frac{1}{1 + e^{-(ax+b)}}$$



Output은 0~1


ex) 0.78 → 고양이라고 판단

## 01


## 로지스틱 회귀

❑ 교재 <모두의 딥러닝> 속 예시에 대한 의문점


공부한 시간	2	4	6	8	10	12	14
합격 여부	불합격	불합격	불합격	합격	합격	합격	합격



1.



2.



## 02


## 시그모이드 함수

- Sigmoid function  $\equiv$  Logistic function
- input값에 대해 단조증가(or 단조감소) 하는 S자형 그래프
- Squashing function (Large input( $-\infty \sim \infty$ )  $\Rightarrow$  Small output(0~1))
- 밑을 자연상수 **e**로 갖는 지수함수가 분모에 포함되는 함수

$$y = \frac{1}{1 + e^{-(ax+b)}}$$







a와 b값에 따라 오차 변화









## 02

## 시그모이드 함수



## 02

## 시그모이드 함수



## 03

## 오차 공식과 로그함수


시그모이드 함수에서  $a, b$  값 구하는 법?

경사 하강법!

오차 구하는 공식 필요!

정답에서 가까워질 수록 Cost function 값은 작고,  
정답에서 멀어질 수록 Cost function 값은 크게 설계!

예측값과 실제 결과값의 차이를 나타내는 함수



## 03

## 오차 공식과 로그함수

Cost  
function

$$\text{cost}(W) = \frac{1}{m} \sum c(H(x), y)$$

$$c(H(x), y) = \begin{cases} -\log(H(x)) & : y = 1 \\ -\log(1 - H(x)) & : y = 0 \end{cases}$$




$$-\{ \underbrace{y\_data \log h}_A + \underbrace{(1 - y\_data) \log(1 - h)}_B \}$$



Loss  
function

: input값에 대한 예측값과 실제값 사이의 오차를 계산하는 함수



02

실습코드 설명

```

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

data = [[2,0],[4,0],[6,0],[8,1],[10,1],[12,1],[14,1]]

x_data = [i[0] for i in data] # 공부시간
y_data = [i[1] for i in data] # 합격여부


# 데이터 시각화
plt.scatter(x_data,y_data) # 점으로 나타내기
#plt.plot(x_data,y_data) # 선으로 나타내기
# x,y 범위 설정
plt.xlim(0,15)
plt.ylim(-0.1,1.1)
plt.show()

# 시그모이드 함수
def sigmoid(x):
    return 1/(1+np.e**(-x))

# a,b 설정
a=b=0

# 학습률
lr = 0.05

```



# 경사하강법

```
# 경사하강법
epoch=2001
for i in range(epoch):
    for x_data, y_data in data:
        # a,b 각각 편미분 값
        a_diff= x_data*(sigmoid(a*x_data+b)-y_data)
        b_diff = sigmoid(a*x_data + b) - y_data
        # a,b 최신화
        a= a- lr*a_diff
        b= b- lr*b_diff

    if i%1000 == 0:
        print("에포크%.4f " %(i))
        print("a=",a)
        print("b=",b)
```

# 학습 결과

```
에포크0.0000  
a= -0.05  
b= -0.025
```

```
에포크1000.0000  
a= 1.4119848217717417  
b= -9.954745130962369
```

```
에포크2000.0000  
a= 1.9068044592233457  
b= -12.951253713260089
```

a 는 증가  
b 는 감소



## 학습된 시그모이드 함수 시각화

```
# 학습시킨 로지스틱 회귀 함수 시각화

x_range= (np.arange(0,15,0.1)) # x 값의 범위 설정
plt.xlim(0,15)
plt.ylim(-0.1,1.1)


plt.plot(np.arange(0,15,0.1),np.array([sigmoid(a*x1+b) for x1 in x_range]))
```

# 학습된 시그모이드 함수 시각화

에포크2000.0000

$a = 1.9068044592233457$

$b = -12.951253713260089$




# 에포크(epoch) 변화시켰을 때

에포크5000.0000

$a = 2.5706374134891763$


$b = -17.728398971271183$



에포크10000.0000

$a = 3.1509359239551777$

$b = -21.847191342449918$



# 03

실습코드  
개조 및 토론

01

## Tensorflow 2.x



# TensorFlow

구글이 2011년에 개발을 시작하여 2015년에 오픈 소스로 공개한 기계학습 라이브러리.

01

# Tensorflow 2.x

[illegible]

```
import tensorflow as tf
mnist = tf.keras.datasets.mnist

(x_train, y_train), (x_test, y_test) = mnist.load_data()
x_train, x_test = x_train / 255.0, x_test / 255.0

model = tf.keras.models.Sequential([
    tf.keras.layers.Flatten(input_shape=(28, 28)),
    tf.keras.layers.Dense(128, activation='relu'),
    tf.keras.layers.Dropout(0.2),
    tf.keras.layers.Dense(10, activation='softmax')
])

model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])

model.fit(x_train, y_train, epochs=5)
model.evaluate(x_test, y_test)
```



## MNIST NN using Numpy

## MNIST NN using Tensorflow 2.x


```
In [39]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import tensorflow as tf
import random

data = [[2, 0], [4, 0], [6, 0], [8, 1], [10, 1], [12, 1], [14, 1]]

x1 = [i[0] for i in data]
y = [i[1] for i in data]

x_g=[i[0] for i in data]
y_g=[i[1] for i in data]
```

```
In [40]: #그래프로 나타내 봅니다.
plt.scatter(x1, y)
plt.xlim(0, 15)
plt.ylim(-.1, 1.1)
plt.grid(True)
```



```
x1_data = np.array(x1)
y_data = np.array(y)

#a = tf.Variable(random.random())
#b = tf.Variable(random.random())

a = tf.Variable(0, dtype=tf.float32)
b = tf.Variable(0, dtype=tf.float32)

compute_loss():
hypothesis = tf.math.sigmoid(a*x1_data+b)
loss = -tf.math.reduce_mean(y_data * tf.math.log(hypothesis) + (1 - y_data) * tf.math.log(1-hypothesis))
return loss
```



```

optimizer = tf.optimizers.SGD(lr=0.05)
epoch = 15001

for i in range(epoch):
    optimizer.minimize(compute_loss, var_list=[a,b])

    if i%1000 == 0:
        print(i, 'a:', a.numpy(), 'b:', b.numpy(), 'loss:', compute_loss().numpy())

```

```

0 a: 0.11428572 b: 0.003571429 loss: 0.5546378
1000 a: 0.6151289 b: -3.9133995 loss: 0.18809369
2000 a: 0.831343 b: -5.517361 loss: 0.13457471
3000 a: 0.98071724 b: -6.602698 loss: 0.11040015
4000 a: 1.098763 b: -7.4521236 loss: 0.09564186
5000 a: 1.1981719 b: -8.163362 loss: 0.08530726
6000 a: 1.2850072 b: -8.782278 loss: 0.0774856
7000 a: 1.3626691 b: -9.334306 loss: 0.07126484
8000 a: 1.4332715 b: -9.835133 loss: 0.06614529
9000 a: 1.4982277 b: -10.295177 loss: 0.061825905
10000 a: 1.5585366 b: -10.721763 loss: 0.05811214
11000 a: 1.6149313 b: -11.120252 loss: 0.05487161
12000 a: 1.6679708 b: -11.494706 loss: 0.052010145
13000 a: 1.7180912 b: -11.848301 loss: 0.04945873
14000 a: 1.7656425 b: -12.183562 loss: 0.047164984
15000 a: 1.8109086 b: -12.50254 loss: 0.045088716

```

#시그모이드 함수를 정의합니다.

```
def sigmoid(x):  
    return 1 / (1 + np.e ** (-x))
```

#경사 하강법을 실행합니다.


```
for i in range(epochs):  
    for x_data, y_data in data:  
        a_diff = x_data*(sigmoid(a*x_data + b) - y_data)  
        b_diff = sigmoid(a*x_data + b) - y_data  
        a = a - lr * a_diff  
        b = b - lr * b_diff  
    if i % 100 == 0: # 1000번 반복될 때마다 각 x_data값에 대한  
        print("epoch=%.f, 기울기=%.04f, 절편=%.04f" % (i, a, b))
```

```
def compute_loss():  
    hypothesis = tf.math.sigmoid(a*xl_data+b)  
    loss = -tf.math.reduce_mean(y_data * tf.math.log(hypothesis)  
                                + (1 - y_data) * tf.math.log(1-hypothesis))  
    return loss
```

```
optimizer = tf.optimizers.SGD(lr=0.05)
```


```
epoch = 15001
```

```
for i in range(epoch):  
    optimizer.minimize(compute_loss, var_list=[a,b])  
    if i%1000 == 0:  
        print(i,'a:', a.numpy(), 'b:', b.numpy(), 'loss:', compute_loss().numpy())
```



```
plt.scatter(x_g, y_g)
plt.xlim(0, 15)
plt.ylim(-.1, 1.1)
x_range = (np.arange(0, 15, 0.1)) #그래프로 나타낼 x값의 범위를 정합니다.
plt.plot(np.arange(0, 15, 0.1), np.array([tf.math.sigmoid(a*x + b) for x in x_range]), '-r')
plt.grid(True)
plt.show
print("기울기=%.04f, 절편=%.04f" % (a.numpy(), b.numpy()))
```

기울기=1.8109, 절편=-12.5025



```
optimizer = tf.optimizers.SGD(lr=0.2)
epoch = 15001
```

lr 0.05 → 0.2

```
for i in range(epoch):
    optimizer.minimize(compute_loss, var_list=[a,b])
    if i%1000 == 0:
        print(i, 'a:', a.numpy(), 'b:', b.numpy(), 'loss:', compute_loss().numpy())
```

```
0 a: 0.4571429 b: 0.014285716 loss: 0.8730116
1000 a: 1.1001173 b: -7.4618363 loss: 0.09548956
2000 a: 1.4341743 b: -9.841531 loss: 0.06608279
3000 a: 1.6686838 b: -11.499739 loss: 0.051972844
4000 a: 1.8547254 b: -12.811153 loss: 0.043172337
5000 a: 2.0105572 b: -13.907752 loss: 0.037025653
6000 a: 2.1452446 b: -14.854552 loss: 0.032446183
7000 a: 2.2641075 b: -15.6895075 loss: 0.028885901
8000 a: nan b: nan loss: nan
9000 a: nan b: nan loss: nan
10000 a: nan b: nan loss: nan
11000 a: nan b: nan loss: nan
12000 a: nan b: nan loss: nan
13000 a: nan b: nan loss: nan
14000 a: nan b: nan loss: nan
15000 a: nan b: nan loss: nan
```



## 1) 수식(이상)과 구현(현실)은 다르다.

결론 부터 말하자면,

가급적이면 수식을 직접 구현하지 말고, `[tf.losses, tf.contrib.losses, tf.nn]` 등에 미리 구현된 함수를 사용해야 한다.

그 이유는,  $\exp(x)$  함수의 값이 지수적으로 증가하므로,  $x$ 가 어느 정도만 ( e.g 800 ) 커져도 `overflow`를 일으키기 때문이다.

위에서  $\text{sigmoid}(z) = (1 / (1 + \exp(-z)))$  이므로,  $z$ 가 -800 만되도  $\exp(-z)$  가 `overflow`를 발생 시켜버리는 것이다.

```
compute_loss():  
hypothesis = tf.math.sigmoid(a*x1_data+b)  
loss = -tf.math.reduce_mean(y_data * tf.math.log(hypothesis) + (1 - y_data) * tf.math.log(1-hypothesis))  
return loss
```



## 2) SSE에 비해 너무 빠른 learning 으로 인한 **oscillation** 문제

cross entropy의 수렴속도는 SSE 에 비해 훨씬 빠르기 때문에,  
learning rate을 줄여주어야 한다.

<https://www.coursera.org/lecture/machine-learning/gradient-descent-in-practice-ii-learning-rate-3iawu>

learning rate이 클 경우 **oscillation**등의 이유로 수렴하지 않는 문제가 발생할 수 있다.  
**oscillation** 이 발생하는 지 알아보는 방법은, training 시 **loss** 값을 출력해보는 것이다.  
**loss**는 항상 줄어들어야 하는데, **loss**가 다시 증가할 경우 **oscillation** 을 의심해볼 수 있다.

따라서 **cross entropy** 를 쓸 경우 **learning rate**을 충분히 작게 해주어야 한다.

```
optimizer = tf.optimizers.SGD(lr=0.2)  
epoch = 15001
```



```
optimizer = tf.optimizers.SGD(lr=0.05)  
epoch = 15001
```



# 04

로지스틱 회귀에서  
퍼셉트론으로




## 01

## 퍼셉트론 개요

출력 값      입력 값

↓      ↙      ↘


$$y = a_1x_1 + a_2x_2 + b$$





## 01

## 퍼셉트론 개요



05

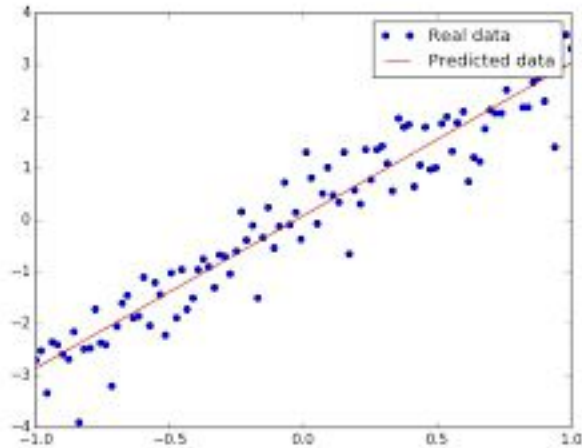
단원 정리

# 01


## 딥러닝의 동작 원리

딥러닝의 기본적인 두 가지 계산 원리

선형 회귀(예측선)  
Linear Regression




로지스틱 회귀(분류)  
Logistic Regression



## 02

## 가설 함수 (Hypothesis)



빨간 선을 예측하고 싶어요!

-> 가설 함수

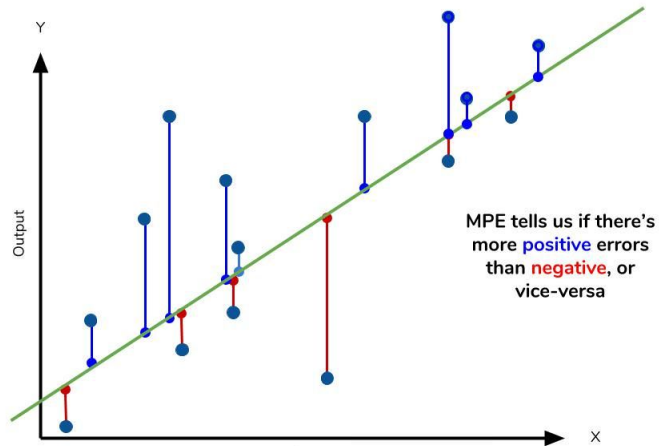
$$H(x) = ax + b$$

우리가 찾아내야 할 변수는  $a, b$

어떻게  $a, b$ 를 맞출 수 있을까?


## 03

## Loss 구하기



## 선형 회귀

MSE를 사용해 예측한 선과 점들의 오차를 계산한다.




## 로지스틱 회귀

두개의 log함수를 합친 Binary Cross Entropy를 사용해 오차를 계산한다.

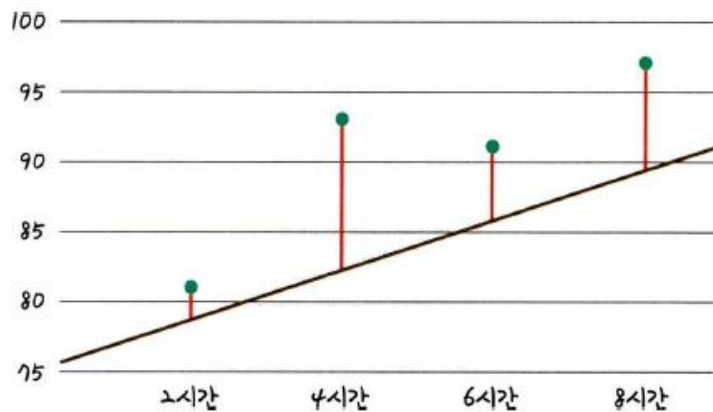
## 03

## Loss 구하기




그런데 이렇게 선을 잘못 예측해 선과 점들 사이의 오차가 클 때

어떻게 해야 오차를 줄일 수 있을까?




## 04

## Optimizer - 경사하강법(GD)



미분 기울기를 이용하는  
경사하강법을 통해 오차를 가장 작은 방향으로 이동시킨다!

->미분 값이 '0'인 지점 찾으면 정답!



Thank you

QnA